

2025年上海财经大学432应用统计真题

题目

解析

题目

一、选择题

1. 下面正确的是：
A. 若 $P(AB) = 0$, 则 A, B 不相容
B. A, B 相容, $P(A)=1 - P(B)$
C. A, B 不相容, 则 $P(\overline{A} \cup \overline{B}) = 1$
D. 有事件 $A_1, A_2...A_n$, 若对于任意的 i 不等于 j , 均有 $P(A_iA_j) = P(A_i)P(A_j)$, 则 $A_1, A_2...A_n$ 相互独立
2. 已知 $P(A) = 0.6, P(B) = 0.5, P(A - B) = 0.5$, 求 $P(B - A)$
A. 0.2
B. 0.3
C. 0.4
D. 0.5
3. X_1, X_2 独立同分布 $P(\lambda)$, 下面哪个一定正确
A. $X_1 + X_2, X_1 - X_2$ 不相关
B. $X_1 + X_2, X_1 - 2X_2$ 不相关
C. $2X_1 + X_2, X_1 - X_2$ 不相关
D. $2X_1 + X_2, X_1 - 2X_2$ 相关

4. 已知经验分布函数

1	2	3	4	5	6	7	8
0.1	0.05	0.1	a	0.2	0.05	0.2	0.05

◀ ▶

则

- A. $F(4)=0.45$
- B. $F(3)=0.15$

C. $F(4.5)=0.5$

D. $F(5.5)=0.75$

5. X_1, X_2 独立, $X_1 \sim N(-1, 6), X_2 \sim N(1, 10)$, $a = P(X_1 + X_2 > 2)$,

$b = P(X_1 - X_2 > 3)$, 则下面哪个是正确的?

A. $a = b$

B. $a < b$

C. $a > b$

D. 无法确定

8. 下面关于箱线图说法正确的是:

A. 箱体两侧面积一样

B. IQR和虚线两段是一样长的

C. 能比较平均数

D. 箱线图可以反映数据离散程度

9. 设 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu_1, \sigma_1^2), i = 1, 2, \dots, m, y_i \stackrel{\text{i.i.d.}}{\sim} N(\mu_2, \sigma_2^2), i = 1, 2, \dots, n$, 则 $\frac{\sigma_1^2}{\sigma_2^2}$ 的

$1 - \alpha$ 置信区间为:

A.

B.

C.

D.

11. 下面哪个 AR 模型是平稳的

A. $X_t = 2X_{t-1} + e_t$

B. $X_t = X_{t-1} + e_t$

C. $X_t = 0.8X_{t-1} + 0.2X_{t-2} + e_t$

D. $X_t = 0.8X_{t-1} - 0.2X_{t-2} + e_t$

12. 下面关于白噪声检验和ADF检验, 正确的是

A. ADF检验用于纯随机性检验

B. ADF检验中, 序列的特征根在单位圆外, 就代表序列平稳

C. 白噪声检验的原假设为时间序列不是白噪声

D. 白噪声检验中, P值小于 α , 认为拒绝原假设, 认为序列不是白噪声序列

二、填空题

1. $f(x, y) = 2x^3 + 2xy, 0 < x < 1, 0 < y < 1$, 求 $E(XY)$
2. $Y \sim U(a, b)$, $X = c_1Y + c_2 \sim U(0, 1)$, c_1, c_2 分别是多少_____
3. $X \sim U(\theta, 3\theta)$, 求 θ 矩估计:
4. $X_1 \sim N(0, 1), X_2 \sim \chi^2(1), X_3 \sim t(1), X_4 \sim F(1, 1)$, 已知
 $P(|X_1| > a_1) = P(|X_2| > a_2)$,
 $P(|X_3| > a_3) = P(|X_4| > a_4)$, 则 a_1 和 a_2 的函数关系与 a_3 和 a_4 的函数关系分别是

5. 无截距项的一元回归中, 扰动项独立同分布且服从 $N(0, \sigma^2)$, 求 $E(\sum e_i^2) = E(SSE) =$
5. 总共五个产品, 两个一等, 三个二等, 不放回抽, 在第一个是一等品的条件下, 第二次抽也是一等品的概率_____
5. 甲乙对同一个正态总体做检验, 显著性水平都是 α , 甲计算得到的p值是 p_1 , 结论是 $\mu = 0$, 乙计算得到的p值是 p_2 , 结论是 $\mu \neq 0$, 问 α 的范围
8. 时间序列 $X_t = 75 + 0.25X_{t-1} - 0.5X_{t-2} + e_t, e_t \sim N(0, 16)$,
 $X_{2022} = 70, X_{2023} = 80$, 求 X_{2024} 的 95%的置信区间_____

三、简答题

1. $F(x, y) = \begin{cases} 1 - e^{-y} - e^{-2x} + e^{-(2x+y)} & x \geq 0, y \geq 0 \\ 0 & \text{O.W.} \end{cases}$
 - (1) 求边际密度
 - (2) X, Y 是否独立
 - (3) X 元件, 已知寿命已经 2 年, 问再多 1 年寿命的概率
 - (4) 一个系统有两个元件, 分别为 X, Y , 若有一个失效则系统失效, 求系统寿命的分布, 写出分布函数。
2. 掷一枚 6 面骰子, 观察正面的数字
 - (1) 写出样本空间

- (2) 写出事件域的定义, 并以题目举例子
- (3) 写出概率定义, 并以题目举例子
- (4) 写出随机变量的定义, 并以题目举例子

3. $f(x) = \lambda^2(x - \mu)e^{-\lambda(x-\mu)}, x \geq \mu$, 其中 μ 已知

(1) 求 $\frac{1}{\lambda}$ 的 MLE

(2) 检验无偏性

(3) 检验相合性

4. X, Y, W 独立, $x_i \stackrel{\text{i.i.d.}}{\sim} N(\mu_1, \sigma^2), y_i \stackrel{\text{i.i.d.}}{\sim} N(\mu_2, \sigma^2), w_i \stackrel{\text{i.i.d.}}{\sim} N(\mu_3, \sigma^2)$, 其中 $\mu_1, \mu_2, \mu_3, \sigma^2$ 均未知, 样本量均为 n

(1) 对检验问题 $\mu_1 - \mu_2 = 0$ 做出假设检验, 当 H_0 成立时, 求使得

$$\frac{c_1(\bar{X} - \bar{Y})}{\sqrt{S_1^2}}, \frac{c_2(\bar{X} - \bar{Y})}{\sqrt{S_1^2 + S_2^2}}, \frac{c_3(\bar{X} - \bar{Y})}{\sqrt{S_1^2 + S_2^2 + S_3^2}}$$
 满足 t 分布的 c_1, c_2, c_3 , 并给出拒绝域

(2) $H_0: \mu_1 = \mu_2 = \mu_3$ vs $H_1: \mu_1, \mu_2, \mu_3$ 不全相同, 给出拒绝域

(3) 是否存在 c , 使得 $\frac{c(\bar{X} - \mu_1)^2}{(\bar{X} - X_1)^2 + (\bar{Y} - Y_1)^2}$ 为 F 分布, 求 c

5. 线性模型 $Y = X\beta + \varepsilon, \varepsilon \sim N(0, \sigma^2 V)$, 其中 V 为正定实对称矩阵且 $V \neq I_n$

(1) 求 β 的 OLS, GLS, MLE, MLE 和 GLS 是否相等?

(2) $H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$ vs $H_1: \beta_1, \beta_2, \dots, \beta_p$ 不全为 0, 求 F 检验和似然比检验的拒绝域, 二者是否等价?

(3) 对于已知的 x_0 , 求 y_0 的最佳线性预测, 并给出理由

四、建模题

1. 一道多元回归图表题, 背景是20世纪70年代美国汽车燃油效率研究, 32款汽车, 10种不同因素, 给出了全模型 (10个因素), 简模型 (向后选择剔除部分变量)

表1: 全模型10个变量的方差分析表, 包含标准误差, p 值, F 值, VIF 等

表2: 简模型3个变量的方差分析表

(1) 全模型是否显著, 某一个变量是否显著

(2) 计算 SSE, SSR

(3) 写出子模型的估计方程, 并解释其中一个变量系数 $\hat{\beta}$ 的含义

- (4) 求一个变量的置信区间
- (5) 两个模型有没有多重共线性
- (6) 比较两个模型哪个合适
- (7) 用子模型回归可以吗? 还有什么地方需要改进? 应该怎么改?

解析

一、选择题

1. 下面正确的是:

- A. 若 $P(AB) = 0$, 则 A, B 不相容
- B. A, B 相容, $P(A) = 1 - P(B)$
- C. A, B 不相容, 则 $P(\overline{A} \cup \overline{B}) = 1$
- D. 有事件 $A_1, A_2, \dots, A_n$, 若对于任意的 i 不等于 j , 均有 $P(A_i A_j) = P(A_i)P(A_j)$, 则 $A_1, A_2, \dots, A_n$ 相互独立

【解析】C

选项 A: $X \sim U(0, 2)$, 记事件 A 为 $0 \leq X \leq 1$, 事件 B 为 $1 \leq X \leq 2$, 则

$P(AB) = 0$, A, B 相容, 故错误, B显然错误, C:

$P(\overline{A} \cup \overline{B}) = P(\overline{A \cap B}) = 1 - P(A \cap B) = 1$, D: 两两独立无法推相互独立, 故错误

2. 已知 $P(A) = 0.6, P(B) = 0.5, P(A - B) = 0.5$, 求 $P(B - A)$

- A. 0.2
- B. 0.3
- C. 0.4
- D. 0.5

【解析】 $P(B - A) = P(B) - P(AB) = P(B) - (P(A) - P(A - B)) = 0.4$

故选C

3. X_1, X_2 独立同分布 $P(\lambda)$, 下面哪个一定正确

- A. $X_1 + X_2, X_1 - X_2$ 不相关
- B. $X_1 + X_2, X_1 - 2X_2$ 不相关
- C. $2X_1 + X_2, X_1 - X_2$ 不相关
- D. $2X_1 + X_2, X_1 - 2X_2$ 相关

【解析】A

4. 已知经验分布函数

1	2	3	4	5	6	7	8
0.1	0.05	0.1	a	0.2	0.05	0.2	0.05

◀ ▶

则

- A. $F(4)=0.45$
- B. $F(3)=0.15$
- C. $F(4.5)=0.5$
- D. $F(5.5)=0.75$

【解析】由分布函数正则性可知： $a=0.25$ ，故 C 正确

5. X_1, X_2 独立, $X_1 \sim N(-1, 6), X_2 \sim N(1, 10)$, $a = P(X_1 + X_2 > 2)$,
 $b = P(X_1 - X_2 > 3)$, 则下面哪个是正确的?
- A. $a = b$
 - B. $a < b$
 - C. $a > b$
 - D. 无法确定

【解析】C

$$P(X_1 + X_2 > 2) = P(N(0, 16) > 2) = 1 - \Phi(0.5)$$
$$P(X_1 - X_2 > 3) = P(N(-2, 16) > 3) = 1 - \Phi(1.25)$$

故选 C

8. 下面关于箱线图说法正确的是:
- A. 箱体两侧面积一样
 - B. IQR和虚线两段是一样长的
 - C. 能比较平均数
 - D. 箱线图可以反映数据离散程度

【解析】D

9. 设 $X_i \overset{i.i.d.}{\sim} N(\mu_1, \sigma_1^2), i = 1, 2, \dots, m, y_i \overset{i.i.d.}{\sim} N(\mu_2, \sigma_2^2), i = 1, 2, \dots, n$, 则 $\frac{\sigma_1^2}{\sigma_2^2}$ 的
 $1 - \alpha$ 置信区间为:
- A.
 - B.
 - C.
 - D.

【解析】

$$\left[\frac{s_x^2}{s_y^2} \cdot \frac{1}{F_{1-\alpha/2}(m-1, n-1)}, \frac{s_x^2}{s_y^2} \cdot \frac{1}{F_{\alpha/2}(m-1, n-1)} \right].$$

11. 下面哪个 AR 模型是平稳的

- A. $X_t = 2X_{t-1} + e_t$
 B. $X_t = X_{t-1} + e_t$
 C. $X_t = 0.8X_{t-1} + 0.2X_{t-2} + e_t$
 D. $X_t = 0.8X_{t-1} - 0.2X_{t-2} + e_t$

【解析】D,

选项 A 特征方程: $1 - 2X = 0$, 特征方程的解为: $X = \frac{1}{2}$

选项 B 特征方程: $1 - X = 0$, 特征方程的解为: $X = 1$

选项 A 特征方程: $1 - 0.8X - 0.2X^2 = 0$, 特征方程的解为: $X = -5, 1$

选项 A 特征方程: $1 - 0.8X + 0.2X^2 = 0$, 特征方程的解为: $2 + i, 2 - i$,

选项 D 的特征方程的解均落在单位圆外, 故平稳

12. 下面关于白噪声检验和ADF检验, 正确的是

- A. ADF检验用于纯随机性检验
 B. ADF检验中, 序列的特征根在单位圆外, 就代表序列平稳
 C. 白噪声检验的原假设为时间序列不是白噪声
 D. 白噪声检验中, P值小于 α , 认为拒绝原假设, 认为序列不是白噪声序列

【解析】D

ADF检验中用于检验时间序列平稳性, 故 A 错误, 序列的特征根在单位圆内代表序列平稳, 故 B 错误, 纯随机检验的 H_0 为: 序列是白噪声序列, 故 C 错误 D 正确, 故选 D

二、填空题

1. $f(x, y) = 2x^3 + 2xy, 0 < x < 1, 0 < y < 1$, 求 $E(XY)$

【解析】 $E(XY) = \int_0^1 \int_0^1 xy(2x^3 + 2xy) dx dy = \frac{19}{45}$

2. $Y \sim U(a, b)$, $X = c_1Y + c_2 \sim U(0, 1)$, c_1, c_2 分别是多少_____

【解析】 $\frac{Y-a}{b-a}, 1 - \frac{Y-a}{b-a} \sim U(0, 1)$, 故 $c_1 = \frac{1}{b-a}, c_2 = \frac{-a}{b-a}$ 或 $c_1 = \frac{-1}{b-a}, c_2 = \frac{b}{b-a}$

3. $X \sim U(\theta, 3\theta)$, 求 θ 矩估计:

【解析】

$$E(X) = 2\theta, \hat{\theta}_{MOM} = \frac{\bar{X}}{2}$$

4. $X_1 \sim N(0, 1), X_2 \sim \chi^2(1), X_3 \sim t(1), X_4 \sim F(1, 1)$, 已知

$$P(|X_1| > a_1) = P(|X_2| > a_2),$$

$$P(|X_3| > a_3) = P(|X_4| > a_4) , \text{ 则 } a_1 \text{ 和 } a_2 \text{ 的函数关系与 } a_3 \text{ 和 } a_4 \text{ 的函数关系分别是}$$

【解析】由于 X_1^2, X_2 同分布, X_3^2, X_4 同分布,

$$P(|X_1| > a_1) = P(|X_1^2| > a_1^2) = P(|X_2| > a_2),$$

$$P(|X_3| > a_3) = P(|X_3^2| > a_3^2) = P(|X_4| > a_4), \text{ 故 } a_1^2 = a_2, a_3^2 = a_4$$

5. 无截距项的一元回归中, 扰动项独立同分布且服从 $N(0, \sigma^2)$, 求 $E(\sum e_i^2) = E(SSE) =$

$$\text{【解析】 } (n-1)\sigma^2$$

5. 总共五个产品, 两个一等, 三个二等, 不放回抽, 在第一个是一等品的条件下, 第二次抽也是一等品的概率_____

$$\text{【解析】 } \frac{1}{4}$$

5. 甲乙对同一个正态总体做检验, 显著性水平都是 α , 甲计算得到的p值是 p_1 , 结论是 $\mu = 0$, 乙计算得到的p值是 p_2 , 结论是 $\mu \neq 0$, 问 α 的范围

$$\text{【解析】 } [p_2, p_1] , \text{ } p \text{ 值定义}$$

8. 时间序列 $X_t = 75 + 0.25X_{t-1} - 0.5X_{t-2} + e_t, e_t \sim N(0, 16)$,

$$X_{2022} = 70, X_{2023} = 80 , \text{ 求 } X_{2024} \text{ 的 95\% 的置信区间}$$

$$\text{【解析】 } \hat{X}_{2024} = 75 + 0.25 * 80 - 0.5 * 70 = 60, \text{Var}(\hat{X}_{2024}) = \text{Var}(e_{2024}) , \text{ 故置信区间为 } \hat{X}_{2024} \pm 1.96 * \sqrt{\text{Var}(e_{2024})} = [52.16, 67.84]$$

三、简答题

$$1. F(x, y) = \begin{cases} 1 - e^{-y} - e^{-2x} + e^{-(2x+y)} & x \geq 0, y \geq 0 \\ 0 & \text{O.W.} \end{cases}$$

(1) 求边际密度

(2) X, Y 是否独立

(3) X 元件, 已知寿命已经 2 年, 问再多 1 年寿命的概率

(4) 一个系统有两个元件, 分别为 X, Y , 若有一个失效则系统失效, 求系统寿命的分布, 写出分布函数。

【解析】

$$(1) f(x) = 2e^{-2x}I_{x \geq 0}, f(y) = e^{-y}I_{y \geq 0}$$

$$(2) F(x, y) = \begin{cases} (1 - e^{-y})(1 - e^{-2x}) & x \geq 0, y \geq 0 \\ 0 & \text{O.W.} \end{cases}, \text{函数可分离, 因此独立}$$

(3) 根据指数分布无记忆性指数分布无记忆性, 可知为 e^{-2x}

(4) 记 $Z = \min(X, Y)$,

$$P(Z > z) = P(X > z, Y > z) = P(X > z)P(Y > z) = e^{-3z}$$

$$F(z) = 1 - P(Z > z) = 1 - e^{-3z}, \text{服从参数为 3 的指数分布}$$

2. 掷一枚 6 面骰子, 观察正面的数字

(1) 写出样本空间

(2) 写出事件域的定义, 并以题目举例子

(3) 写出概率定义, 并以题目举例子

(4) 写出随机变量的定义, 并以题目举例子

【解析】

$$(1) \Omega = \{1, 2, \dots, 6\}$$

(2) 设 Ω 为一样本空间, $\mathcal{F}$ 为 Ω 的某些子集所组成的集合类, 如果 $\mathcal{F}$ 满足:

i. $\Omega \in \mathcal{F}$;

ii. 若 $A \in \mathcal{F}$, 则对立事件 $\bar{A} \in \mathcal{F}$;

iii. 若 $A_n \in \mathcal{F}, n = 1, 2, \dots$, 则可列并 $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$,

则称 $\mathcal{F}$ 为一个事件域, 又称为 σ 域或 σ 代数。

此题样本空间含有 6 个样本点 $\Omega = \{1, 2, \dots, 6\}$, 则其事件域 $\mathcal{F}$ 是由空集 $\emptyset$, 6 个单元素集, $\binom{6}{2}$ 个双元素集, $\binom{6}{3}$ 个三元素集, $\binom{6}{4}$ 个四元素集, 6 个五元素集, 1 个六元素集, 组成的集合类, 这时 $\mathcal{F}$ 中共有

$$\binom{6}{0} + \binom{6}{1} + \binom{6}{2} + \dots + \binom{6}{6} = 2^6 \text{ 个事件。}$$

(3) 设 Ω 为样本空间, $\mathcal{F}$ 为 Ω 上的 σ -域, 那么 $\mathcal{F}$ 上的函数 P 称为概率测度 (简称概率), 如果它满足

(1) 非负性: 对任何 $A \in \mathcal{F}, P(A) \geq 0$;

(2) 规范性: $P(\Omega) = 1$;

(3) 可列可加性: 对 $\mathcal{F}$ 中互斥的可列个事件 $\{A_n : n \geq 1\}$, 有

$$P\left(\bigcup_{n \geq 1} A_n\right) = \sum_{n \geq 1} P(A_n).$$

这时, 称 $P(A)$ 是事件 A 发生的概率, 且称满足上面两个定义的三要素 $(\Omega, \mathcal{F}, P)$ 是一个概率空间,

称三元体 $(\Omega, \mathcal{F}, P)$ 为概率空间, 其中 Ω 是样本空间, $\mathcal{F}$ 是关于这个样本空间的一个事件域, P 是定义在 $\mathcal{F}$ 上的概率.

以此题为例, $P(1) = \frac{1}{6}, P(1, 2) = P(1) + P(2) = \frac{1}{3}$

(4) 设 $(\Omega, \mathcal{F}, P)$ 是概率空间, $\xi: \Omega \rightarrow \mathbf{R}$ 是 Ω 上的函数. 称 ξ 是随机变量, 如果对任何 $x \in \mathbf{R}$, $\{\xi(\omega) \leq x\} := \{\omega \in \Omega: \xi(\omega) \leq x\} \in \mathcal{F}$.

在本题中, 记 $X =$ “掷一颗骰子, 正面向上的点数”, 则 X 是离散均匀分布, 可能取值为 1, 2, 3, 4, 5, 6, 且各个取值概率相等, 均为 $\frac{1}{6}$

3. $f(x) = \lambda^2(x - \mu)e^{-\lambda(x - \mu)}, x \geq \mu$, 其中 μ 已知

(1) 求 $\frac{1}{\lambda}$ 的 MLE

(2) 检验无偏性

(3) 检验相合性

【解析】

$$(1) L(x_1, x_2, \dots, x_n; \lambda) = \lambda^{2n} \cdot \prod_{i=1}^n (x_i - \mu) \cdot e^{-\lambda \sum_{i=1}^n (x_i - \mu)} I_{\{x_{(1)} \geq \mu\}}$$

$$\ln L = 2n \ln \lambda + \sum_{i=1}^n \ln(x_i - \mu) - \lambda \sum_{i=1}^n (x_i - \mu)$$

$$\frac{\partial \ln L}{\partial \lambda} = \frac{2n}{\lambda} - \sum_{i=1}^n (x_i - \mu) = 0, \quad \left(\frac{1}{\lambda}\right)_{\text{MLE}} = \frac{1}{2n} \sum_{i=1}^n (x_i - \mu)$$

$$(2) \text{ 记 } y_i = x_i - \mu, \text{ 则 } f(y) = \lambda^2 y e^{-\lambda y} I_{\{y \geq 0\}} \sim Ga(2, \lambda), \quad \sum_{i=1}^n y_i \sim Ga(2n, \lambda)$$

$$E\left(\frac{1}{\lambda}\right)_{\text{MLE}} = \frac{1}{2n} \sum_{i=1}^n y_i = \frac{1}{2n} \cdot 2n \cdot \frac{1}{\lambda} = \frac{1}{\lambda}, \text{ 因此是无偏估计}$$

(3) 随机变量序列 $\{x_i - \mu\}$ 独立同分布, 且期望存在, 由辛钦大数定律, 可知

$$\frac{1}{n} \sum_{k=1}^n (x_i - \mu) \xrightarrow{P} \frac{2}{\lambda}$$

$$\text{即 } \frac{1}{2n} \sum_{k=1}^n (x_i - \mu) \xrightarrow{P} \frac{1}{\lambda}, \text{ 因此是相合估计}$$

4. X, Y, W 独立, $x_i \stackrel{\text{i.i.d.}}{\sim} N(\mu_1, \sigma^2), y_i \stackrel{\text{i.i.d.}}{\sim} N(\mu_2, \sigma^2), w_i \stackrel{\text{i.i.d.}}{\sim} N(\mu_3, \sigma^2)$, 其中 $\mu_1, \mu_2, \mu_3, \sigma^2$ 均未知, 样本量均为 n

(1) 对检验问题 $\mu_1 - \mu_2 = 0$ 做出假设检验, 当 H_0 成立时, 求使得

$$\frac{c_1(\bar{X} - \bar{Y})}{\sqrt{S_1^2}}, \frac{c_2(\bar{X} - \bar{Y})}{\sqrt{S_1^2 + S_2^2}}, \frac{c_3(\bar{X} - \bar{Y})}{\sqrt{S_1^2 + S_2^2 + S_3^2}}$$
 满足 t 分布的 c_1, c_2, c_3 , 并给出拒绝域

(2) $H_0: \mu_1 = \mu_2 = \mu_3$ vs $H_1: \mu_1, \mu_2, \mu_3$ 不全相同, 给出拒绝域

(3) 是否存在 c , 使得 $\frac{c(\bar{X} - \mu_1)^2}{(\bar{X} - X_1)^2 + (\bar{Y} - Y_1)^2}$ 为 F 分布, 求 c

【解析】

(1) 当 H_0 成立时, 有: $\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{2}{n}\sigma}} \sim N(0, 1), \frac{(n-1)S_1^2}{\sigma^2} \sim \chi^2(n-1),$

$$\frac{(n-1)(S_1^2 + S_2^2)}{\sigma^2} \sim \chi^2(2n-2), \frac{(n-1)(S_1^2 + S_2^2 + S_3^2)}{\sigma^2} \sim \chi^2(3n-3)$$

由 Fisher 引理, 知 $\bar{X}, \bar{Y}, S_1^2, S_2^2, S_3^2$ 两两独立

又 $P(\bar{X} < a_1, S_1^2 < a_2, \bar{Y} < a_3, S_2^2 < a_4, S_3^2 < a_5)$

$$= P(\bar{X} < a_1, S_1^2 < a_2) * P(\bar{Y} < a_3, S_2^2 < a_4) * P(S_3^2 < a_5)$$

$$= P(\bar{X} < a_1) * P(S_1^2 < a_2) * P(\bar{Y} < a_3) * P(S_2^2 < a_4) * P(S_3^2 < a_5)$$

故 $\bar{X}, \bar{Y}, S_1^2, S_2^2, S_3^2$ 相互独立, 因此

$$t_1 = \frac{\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{2}{n}\sigma}}}{\sqrt{\frac{(n-1)S_1^2}{(n-1)\sigma^2}}} \sim t(n-1), c_1 = \sqrt{\frac{n}{2}}, \text{拒绝域 } |t_1| \geq t_{1-\alpha/2}(n-1)$$

$$t_2 = \frac{\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{2}{n}\sigma}}}{\sqrt{\frac{(n-1)(S_1^2 + S_2^2)}{(2n-2)\sigma^2}}} \sim t(2n-2), c_2 = \sqrt{n}, \text{拒绝域 } |t_2| \geq t_{1-\alpha/2}(2n-2)$$

$$t_3 = \frac{\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{2}{n}\sigma}}}{\sqrt{\frac{(n-1)(S_1^2 + S_2^2 + S_3^2)}{(3n-3)\sigma^2}}} \sim t(3n-3), c_3 = \sqrt{\frac{3n}{2}}, \text{拒绝域 } |t_3| \geq t_{1-\alpha/2}(3n-3)$$

$$(2) L = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^{3n} \exp \left\{ -\frac{\sum_{i=1}^n \left[(x_i - \mu_1)^2 + (y_i - \mu_2)^2 + (w_i - \mu_3)^2 \right]}{2\sigma^2} \right\}$$

在全参数空间下:

$$\ln L = \text{const} - 3n \ln \sigma - \frac{\sum_{i=1}^n \left[(x_i - \mu_1)^2 + (y_i - \mu_2)^2 + (w_i - \mu_3)^2 \right]}{2\sigma^2}$$

$$\frac{\partial \ln L}{\partial \mu_1} = -\frac{1}{2\sigma^2} \cdot 2 \sum_{i=1}^n (x_i - \mu_1) = 0$$

$$\frac{\partial \ln L}{\partial \mu_2} = -\frac{1}{2\sigma^2} \cdot 2 \sum_{i=1}^n (y_i - \mu_2) = 0$$

$$\frac{\partial \ln L}{\partial \mu_3} = -\frac{1}{2\sigma^2} \cdot 2 \sum_{i=1}^n (w_i - \mu_3) = 0$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{3n}{2\sigma^2} + \frac{\sum_{i=1}^n \left[(x_i - \mu_1)^2 + (y_i - \mu_2)^2 + (w_i - \mu_3)^2 \right]}{2(\sigma^2)^2} = 0$$

解得

$$\hat{\mu}_1 = \bar{x}, \hat{\mu}_2 = \bar{y}, \hat{\mu}_3 = \bar{w}, \hat{\sigma}^2 = \frac{\sum_{i=1}^n [(x_i - \bar{x})^2 + (y_i - \bar{y})^2 + (w_i - \bar{w})^2]}{3n}$$

当 H_0 成立时,

$$\ln L = \text{const} - 3n \ln \sigma - \frac{\sum_{i=1}^n [(x_i - \mu_1)^2 + (y_i - \mu_1)^2 + (w_i - \mu_1)^2]}{2\sigma^2}$$

$$\frac{\partial \ln L}{\partial \mu_1} = -\frac{1}{2\sigma^2} \cdot 2 \sum_{i=1}^n [(x_i - \mu_1) + (y_i - \mu_1) + (w_i - \mu_1)] = 0$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{3n}{2\sigma^2} + \frac{\sum_{i=1}^n [(x_i - \mu_1)^2 + (y_i - \mu_1)^2 + (w_i - \mu_1)^2]}{2(\sigma^2)^2} = 0$$

解得

$$\hat{\mu}_1 = \frac{\bar{x} + \bar{y} + \bar{w}}{3}, \hat{\sigma}^2 = \frac{\sum_{i=1}^n [(x_i - \hat{\mu}_1)^2 + (y_i - \hat{\mu}_1)^2 + (w_i - \hat{\mu}_1)^2]}{3n}$$

记

$$SST = \frac{\sum_{i=1}^n [(x_i - \hat{\mu}_1)^2 + (y_i - \hat{\mu}_1)^2 + (w_i - \hat{\mu}_1)^2]}{3n}$$

$$SSE = \frac{\sum_{i=1}^n [(x_i - \bar{x})^2 + (y_i - \bar{y})^2 + (w_i - \bar{w})^2]}{3n}$$

因此

$$\Lambda = \frac{\sup_{\theta \in \Theta} L}{\sup_{\theta \in \Theta_0} L} = \frac{(2\pi \cdot \frac{SSE}{3n})^{-\frac{3n}{2}} \exp(-\frac{3n}{2})}{(2\pi \cdot \frac{SST}{3n})^{-\frac{3n}{2}} \exp(-\frac{3n}{2})}$$

$$= \left(\frac{SSE}{SST} \right)^{-\frac{3n}{2}}$$

$$H_0 \text{ 成立时, } SST - SSE, SSE \text{ 独立, 且 } \frac{SST - SSE}{3} \sim \chi^2(2), \frac{SSE}{n-3} \sim \chi^2(3n-3),$$

$$\text{检验统计量 } F = \frac{(SST - SSE)/2}{SSE/3n-3} \sim F(2, 3n-3), \text{ 拒绝域 } F \geq F_{1-\alpha}(2, 3n-3)$$

(3) 由多元正态分布的性质: 独立和不相关等价, 以及 $\text{Cov}(\bar{X}, \bar{X} - X_1) = 0$, 知二者独立, 且

$$\frac{(\bar{X} - \mu_1)^2}{\frac{1}{n}\sigma^2} \sim \chi^2(1), \frac{(\bar{X} - X_1)^2}{\frac{n-1}{n}\sigma^2} \sim \chi^2(1), \frac{(\bar{Y} - Y_1)^2}{\frac{n-1}{n}\sigma^2} \sim \chi^2(1) \text{ 且独立}$$

$$\text{故 } \frac{\frac{(\bar{X} - \mu_1)^2}{\frac{1}{n}\sigma^2}}{\left(\frac{(\bar{X} - X_1)^2}{\frac{n-1}{n}\sigma^2} + \frac{(\bar{Y} - Y_1)^2}{\frac{n-1}{n}\sigma^2} \right) / 2} \sim F(1, 2), c = 2n - 2$$

5. 线性模型 $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \boldsymbol{\varepsilon} \sim N(0, \sigma^2 \mathbf{V})$, 其中 $\mathbf{V}$ 为正定实对称矩阵且 $\mathbf{V} \neq \mathbf{I}_n$

(1) 求 $\boldsymbol{\beta}$ 的 OLS, GLS, MLE, MLE 和 GLS 是否相等?

(2) $H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$ vs $H_1: \beta_1, \beta_2, \dots, \beta_p$ 不全为 0, 求 F 检验和似然比检验的拒绝域, 二者是否等价?

(3) 对于已知的 $\mathbf{x}_0$, 求 y_0 的最佳线性预测, 并给出理由

【解析】

(1)

$$\text{OLS} : \hat{\beta}_{\text{OLS}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

GLS :

对模型左乘 $\mathbf{V}^{-\frac{1}{2}}$, 根据正态分布的性质, 知 $\mathbf{V}^{-\frac{1}{2}}\boldsymbol{\varepsilon} \sim N(0, \sigma^2\mathbf{I}_n)$, 符合 Gauss-Markov 定理的前提, 对模型 $\mathbf{V}^{-\frac{1}{2}}\mathbf{Y} = \mathbf{V}^{-\frac{1}{2}}\mathbf{X}\boldsymbol{\beta} + \mathbf{V}^{-\frac{1}{2}}\boldsymbol{\varepsilon}$ 进行OLS估计便可, 得

$$\hat{\beta}_{\text{GLS}} = (\mathbf{X}'\mathbf{V}^{-\frac{1}{2}}\mathbf{V}^{-\frac{1}{2}}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-\frac{1}{2}}\mathbf{V}^{-\frac{1}{2}}\mathbf{Y} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-1}\mathbf{Y}$$

MLE :

$$\text{左乘 } \mathbf{V}^{-\frac{1}{2}}\mathbf{Y} = \mathbf{V}^{-\frac{1}{2}}\mathbf{X}\boldsymbol{\beta} + \mathbf{V}^{-\frac{1}{2}}\boldsymbol{\varepsilon}, \mathbf{V}^{-\frac{1}{2}}\boldsymbol{\varepsilon} \sim N(0, \sigma^2\mathbf{I}_n)$$

扰动项满足经典假设, 故 MLE 和 GLS 相等

$$\hat{\beta}_{\text{MLE}} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-1}\mathbf{Y}$$

(2)

$$F \text{ 检验统计量为 } F = \frac{\mathbf{Y}'(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n')\mathbf{Y}/p}{\mathbf{Y}'(\mathbf{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')\mathbf{Y}/n-p-1}$$

拒绝域: $\{F > F_{1-\alpha}(p, n-p-1)\}$

对模型做变换 $\mathbf{V}^{-\frac{1}{2}}\mathbf{Y} = \mathbf{V}^{-\frac{1}{2}}\mathbf{X}\boldsymbol{\beta} + \mathbf{V}^{-\frac{1}{2}}\boldsymbol{\varepsilon}$, 记为 $\mathbf{W} = \mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon}^*$, $\boldsymbol{\varepsilon}^* \sim N(0, \sigma^2\mathbf{I}_n)$

$$\text{似然比检验统计量为: } F = \frac{\mathbf{W}'(\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}' - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n')\mathbf{W}/p}{\mathbf{W}'(\mathbf{I}_n - \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}')\mathbf{W}/n-p-1} \stackrel{H_0}{\sim} F(p, n-p-1)$$

$$F = \frac{\mathbf{Y}'\mathbf{V}^{-\frac{1}{2}}(\mathbf{V}^{-\frac{1}{2}}\mathbf{X}(\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-\frac{1}{2}} - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n')\mathbf{V}^{-\frac{1}{2}}\mathbf{Y}/p}{\mathbf{Y}'\mathbf{V}^{-\frac{1}{2}}(\mathbf{I}_n - \mathbf{V}^{-\frac{1}{2}}\mathbf{X}(\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-\frac{1}{2}})\mathbf{V}^{-\frac{1}{2}}\mathbf{Y}/n-p-1} \stackrel{H_0}{\sim} F(p, n-p-1)$$

拒绝域: $\{F > F_{1-\alpha}(p, n-p-1)\}$

由于 $\mathbf{V} \neq \mathbf{I}_n$, 因此二者不等价

(3) 由 Gauss-Markov 定理可知 y_0 的最佳线性预测 $\hat{y}_0 = \mathbf{x}_0(\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-1}\mathbf{Y}$

四、建模题

1. 一道多元回归图表题, 背景是20世纪70年代美国汽车燃油效率研究, 32款汽车, 10种不同因素, 给出了全模型 (10个因素), 简模型 (向后选择剔除部分变量)

表1: 全模型10个变量的方差分析表, 包含标准误差, p 值, F 值, VIF 等

表2: 简模型3个变量的方差分析表

(1) 全模型是否显著, 某一个变量是否显著

(2) 计算 SSE, SSR

(3) 写出子模型的估计方程, 并解释其中一个变量系数 $\hat{\beta}$ 的含义

(4) 求一个变量的置信区间

(5) 两个模型有没有多重共线性

(6) 比较两个模型哪个合适

(7) 用子模型回归可以吗？还有什么地方需要改进？应该怎么改？

【解析】

(1) 看表中P值即可

(2) 根据 $F = \frac{SSR/k}{SSE/(n-k-1)}$, $SE = \sqrt{\frac{SSE}{n-k-1}}$, $k = 10$ 计算即可

(3) 在其他变量不变的情况下，该变量每增加一个单位，因变量增加 $\hat{\beta}$ 个单位

(4) $\left[\hat{\beta}_i - t_{0.975}(21)\hat{\sigma}_{\hat{\beta}}, \hat{\beta}_i + t_{0.975}(21)\hat{\sigma}_{\hat{\beta}} \right]$

(5) 看表中VIF，大于10则存在多重共线性

(6) 从模型的显著性，变量的显著性，是否有多重共线性，实际意义等作答均可

(7) 32条数据，数据量较少；可能某些重要变量未包含；可以搜集更多数据，选择更多变量进行回归，再进行变量选择